

Documento Técnico

Agente Postventa Zapata · Arquitectura, Topics, Flows y Knowledge

Hackatón IA Agéntica, tercera edición · Equipo 35 · Org 00DgK00000VXSyCUAX · API 67.0 · 12 de agosto de 2026

1 · El reto y el valor

Corporación Zapata distribuye y da servicio a camiones pesados en nueve talleres del país. La postventa concentra el dolor operativo: el cliente llama para saber si su unidad tiene garantía, para agendar taller o porque quedó varado en carretera. Cada una de esas llamadas ocupa a un asesor que debe cruzar a mano el VIN, el kilometraje, la póliza del modelo y la disponibilidad del taller. Son cuatro sistemas distintos para responder una pregunta.

El Agente Postventa Zapata resuelve esas cuatro conversaciones de extremo a extremo, en lenguaje natural, con efecto real en el CRM: crea y mueve órdenes de servicio, levanta reportes de asistencia en carretera, evalúa cobertura contra la póliza del modelo y abre casos en la cola de postventa con la conversación completa adjunta. El asesor deja de transcribir y empieza a resolver lo que sólo una persona puede resolver.

2 · Arquitectura

Un solo agente Agentforce con una capa de clasificación —el router— que enruta a seis Topics. Cuatro resuelven trabajo; dos son guardrails de contención que impiden que el agente responda fuera de su alcance. Las acciones son Flows autolaunched y clases Apex invocables.

La decisión de fondo: **ninguna regla de negocio vive únicamente en lenguaje natural**. El umbral de garantía es un custom setting, la anticipación mínima es un campo de la sucursal, qué franja es reservable lo decide una consulta y no una instrucción. Las instrucciones dicen cómo hablar y cuándo llamar a qué; lo que se puede o no se puede hacer lo deciden Apex, los Flows y diecisiete reglas de validación.

Las tres capas

Capa	Qué contiene
Conversación	Router de clasificación (sfdc_ai__DefaultEinsteinHyperClassifier) y seis Topics con sus instrucciones. Idioma es_MX.
Ejecución	Seis acciones: tres clases Apex invocables y tres Flows autolaunched, más un subflow de traza. Cada una devuelve un motivo de bloqueo estable cuando no puede actuar.
Datos y garantías	Objetos personalizados (Sucursal__c, Slot_Taller__c, Modelo_Sucursal__c, Regla_Cobertura__c, Unidad_Varada__c, Log_Agente__c), el custom setting Parametros_Garantia__c y 17 reglas de validación activas.

Variables de contexto

El agente recibe cuatro variables enlazadas de la sesión: RoutableId (MessagingSession.Id, que viaja como identificador de correlación a toda la traza), EndUserId, ContactId y EndUserLanguage. El identificador de correlación es lo que amarra la primera pregunta del cliente con el caso que termina atendiendo un asesor.

3 · Configuración de Topics

agent_router — clasificación

Da la bienvenida en español y decide el Topic según la intención y el historial. Los criterios están escritos como reglas explícitas, no como una descripción vaga:

- Cobertura, mantenimiento, costos, códigos de falla, procedimientos o políticas → conocimiento_y_respuestas.
- Agendar, reprogramar o cancelar una cita → agendar_servicio_taller.
- Unidad detenida, falla en carretera, emergencia o grúa → atencion_unidades_varadas.
- Petición explícita de una persona, queja o inconformidad → escalamiento_asesor_humano.
- Ajeno a postventa de camiones → off_topic.
- «Tengo un problema», «necesito ayuda» o cualquier intención incompleta → ambiguous_question. **Una petición ambigua nunca se escala: primero se pide aclaración.**

conocimiento_y_respuestas

Atiende garantías, coberturas, planes de mantenimiento, costos, códigos de falla, protocolos de emergencia, requisitos de taller y tiempos de refacciones. Sus directrices gobiernan la honestidad de la respuesta:

- Llama siempre a la acción de conocimiento; nunca responde de memoria.
- Responde **únicamente** con el campo Contenido de los artículos. Prohibido inventar o inferir kilometrajes, costos, tiempos o coberturas que no aparezcan textualmente.
- Todo resumen abre exactamente con «El material no verificado consultado indica:», nunca con «la garantía cubre» o «está cubierto». No convierte contenido sintético en un veredicto aunque repita sus cifras.
- Antes del contenido escribe tres líneas obligatorias con los valores literales devueltos: Material consultado, Estado de la fuente y Advertencia de procedencia. Si un valor viene vacío escribe «dato no devuelto»; nunca inventa un sustituto.
- Si el cliente pregunta si la información es oficial, repite el estado literal de la fuente. Tiene prohibido decir que proviene de sistemas verificados de Zapata: eso no le consta.
- Si el número de serie no existe en el padrón, el aviso va antes que cualquier otra línea y el material no se presenta como la cobertura de esa unidad.

agendar_servicio_taller

- Compuerta de identidad: sin un VIN válido de 17 caracteres **no ejecuta** la creación de la orden; explica por qué y ofrece un asesor.
- Consulta disponibilidad siempre antes de agendar, aunque el cliente ya haya dicho el día, y ofrece numeradas sólo las opciones que esa acción devolvió.
- Manda el taller tal como lo dijo el cliente, con acentos: la acción resuelve el catálogo. Nunca reintenta la misma sucursal cambiando datos.
- Nunca llena el código de modelo: no puede saber qué modelo es una unidad, y adivinarlo haría que la validación de cobertura del taller diga cualquier cosa.
- Autonomía explícita: la petición del cliente **ya es su autorización**. Ejecuta y reporta, sin pedir un «¿confirmas?» adicional.
- Al reprogramar, el folio no cambia: se lo confirma al cliente para que sepa que no tiene dos citas.
- Nunca menciona identificadores internos. El cliente sólo recibe folios, días y horas.

atencion_unidades_varadas

- Primer mensaje siempre: confirmar que el operador esté fuera del carril y con intermitentes encendidas.
- Con la carretera y la descripción de la falla **ya registra**: no espera al VIN ni al kilómetro, que se completan después. Pedirlos primero sólo retrasa el auxilio.

- Tampoco espera a que el operador confirme que está a salvo: una unidad sobre el carril es más urgente, no menos. Registra con las respuestas en falso y lee el aviso de seguridad antes del folio.
- Las respuestas de seguridad van en verdadero sólo si el operador las confirmó. Si no contestó, van en falso: no se suponen.

escalamiento_asesor_humano

- Escala sin discutir ante petición explícita, queja o inconformidad, autorización de garantía o monto a facturar, y riesgo de seguridad.
- Resume el motivo en una línea antes de registrar, para que el asesor tenga contexto.
- No declara una transferencia en vivo: **esta organización enruta mediante Case**. Prometer otra cosa sería mentir sobre lo que la org puede sostener.
- Si el registro falla, no inventa folio ni afirma que escaló: comunica el error real.

off_topic y ambiguous_question — contención

Su trabajo es no actuar. Off-topic declina lo ajeno a postventa de camiones —incluidas compra de unidades, financiamiento, seguros y recursos humanos— y ofrece un asesor. Ambiguous_question pide la precisión mínima con opciones concretas. Sin estos dos, un agente que escala cualquier mensaje vago o que opina fuera de su alcance hace daño silencioso que ninguna prueba de registros creados detecta.

4 · Lógica de los Flows

Cuatro Flows productivos concentran las reglas deterministas. Ninguno confía en lo que diga el modelo: cada uno vuelve a comprobar sus condiciones contra la organización.

Flow	Lógica
Crear_Orden_Servicio	Recibe VIN, identificador de franja y código de sucursal. Valida que la franja exista, que su procedencia esté acreditada —rechaza con SLOT_NO_VERIFICADO cualquier franja de capacidad asumida—, que se respete la anticipación mínima de esa sucursal y que quede cupo. Crea la WorkOrder ligada a la unidad y a la franja, ocupa el lugar y devuelve el folio. Deriva su clave de idempotencia de la conversación, así que repetir la petición no agenda dos veces.
Reprogramar_Orden_Servicio	Recibe el folio existente y la nueva franja. Mueve la cita conservando el folio —el invariante es «mueve, no crea»— y libera el lugar anterior. Cuando la ventana de reprogramación ya no lo permite, deriva a un caso para que un asesor lo revise, en lugar de fallar en silencio o inventar un cambio.
Crear_Reporte_Unidad_Varada	Levanta Unidad_Varada__c con lo mínimo indispensable: carretera y descripción de la falla. VIN y kilómetro son opcionales a propósito. Marca prioridad crítica, guarda las respuestas de seguridad tal como se recibieron y devuelve el aviso de seguridad junto con el folio de asistencia.
Registrar_Log_Agente	Subflow invocado por los tres anteriores en las rutas de éxito, bloqueo y error. Escribe Log_Agente__c con el identificador de correlación, el subagente, la acción, el resultado y el registro afectado. Al ser subflow y no una llamada opcional, ninguna acción puede olvidar su traza.

Lo que no decide el modelo

- La cobertura de garantía se evalúa contra el custom setting Parametros_Garantia__c —250 000 km y 24 meses— usando el odómetro registrado, y devuelve CUBIERTO, NO_CUBIERTO o REQUIERE_DATO.
- Diecisiete reglas de validación activas protegen la consistencia. Entre ellas Error_Requiere_Codigo, que obliga a que todo resultado ERROR o BLOCKED traiga código o guardrail, para que un bloqueo siempre sea auditable.
- El catálogo operativo comprende nueve talleres y 803 franjas; sólo las marcadas OPERACIONAL_VERIFICADO son reservables, y la acción de disponibilidad no ofrece ninguna otra.

5 • Artículos de Knowledge utilizados

La acción estándar de Knowledge no era funcional en la organización (Data Library sin aprovisionar), así que se construyó una clase Apex invocable propia, `BuscarConocimientoPostventa`, con búsqueda SOSL sobre los artículos publicados y respaldo SOQL por título y resumen. Devuelve el contenido convertido a texto plano y limitado a tres artículos, lo que hace la respuesta determinista y citable: el agente reproduce el artículo en vez de parafrasearlo. Además comprueba si el número de serie dictado existe en el padrón y escribe su traza con el artículo consultado y su versión de política.

Corpus: **20 artículos publicados en español.**

Artículo	Qué resuelve
Cobertura de garantia basica por componente	Qué cubre la garantía de fábrica y por cuánto tiempo
Garantia extendida de tren motriz	Componentes incluidos, vigencia, deducible y condiciones
Garantia de refacciones y mano de obra	Plazos por tipo de refacción
Causas de invalidacion de garantia	Qué la cancela: aceites no especificados, sobrepeso, alteración de odómetro
Requisitos documentales para reclamo de garantia	Qué papeles pide Zapata
Servicio preventivo de 10,000 km	Alcance, duración y costo aproximado
Servicio preventivo de 40,000 km	Alcance, duración y costo aproximado
Servicio preventivo de 80,000 km y mayores	Incluye revisión de turbocargador y admisión
Aceites y lubricantes autorizados	Especificaciones admitidas
Requisitos para ingresar una unidad a taller	Condiciones de recepción
Codigos de falla SPN y FMI mas frecuentes	Interpretación y acción sugerida
Luces de tablero: significado y accion inmediata	Qué hacer ante cada testigo
Fallas comunes del sistema de frenos de aire	Diagnóstico y riesgos
Regeneracion del filtro de particulas (DPF)	Procedimiento y señales
Sistema de post-tratamiento y AdBlue	Consumo, calidad y fallas
Protocolo de unidad varada en carretera	Qué hacer antes de que llegue el auxilio
Asistencia en carretera: cobertura y tiempos	Qué cubre y en cuánto responde
Politica de grua y traslado de unidades	Cuándo aplica y hasta dónde
Politica de unidad sustituta	Cuándo procede
Tiempos de entrega de refacciones	Plazos por tipo de componente

Procedencia declarada. El material del reto es sintético y no verificado. Cada artículo lleva su versión de política, la acción la devuelve, y el agente la comunica en lenguaje natural sin presentarla como póliza oficial. Si el cliente cuestiona la fuente, repite su estado literal. Es la diferencia entre un agente que cita y uno que finge certeza.

6 • Trazabilidad

Cada acción escribe en `Log_Agente__c` con `Correlation_Id__c`, `Related_Record_Id__c`, `Guardrail_Triggered__c`, `Odometer_Used__c` y su origen, `Policy_Version__c` y `Unit_Verified__c`. La organización acumula 361 registros generados durante construcción y pruebas. Un mismo identificador de correlación permite reconstruir una conversación completa: qué subagente actuó, qué acción ejecutó, sobre qué registro y con qué resultado.

7 · Verificación

Lo que sostiene este documento no es una corrida manual, son gates que cualquiera puede volver a ejecutar contra la organización:

- 139/139 pruebas unitarias del servidor y sus reglas.
- 80/80 comprobaciones del contrato de la Agent API.
- 41 casos e2e de rutas, interfaz y seguridad; 21/21 pruebas Apex en la org.
- 0 violaciones del sistema de diseño en siete estados de pantalla, contraste incluido.
- Conversaciones completas releídas de Salesforce por el CLI —nunca por la propia aplicación— y una sonda de generalidad que recorre las 15 unidades de la flota y los nueve talleres con datos que no son los del demo.

8 · Límites declarados

Por rigor y no por omisión:

- El escalamiento entrega un Case enrutado a la cola de postventa, no una transferencia en vivo por Omni-Channel, y el agente lo comunica en esos términos.
- Ocho de los nueve talleres publican horario pero su cupo no está confirmado con el taller. El agente no los ofrece: dice que el horario existe, quién lo confirma y en qué taller sí se puede apartar hoy. Mientras esas franjas no se verifiquen, sólo Querétaro reserva en el acto.
- El modelo T680 no está dado de alta en la red. El agente lo dice y pasa con un asesor en vez de ofrecer una búsqueda que no puede terminar bien. Cargar esas filas es una decisión operativa del negocio.
- La acción de conocimiento ya escribe su traza; falta refrescar la acción en Agent Builder para que el planner le pase el identificador de correlación. El esquema de entrada de una acción no se despliega por metadata.